

Supplementary Information (SI)

CO2 Cycloaddition Catalyst-Substrate Transferability Diagnostic

Supplementary Information

承接正文 paper_draft_JC_Chinese.md。本文件汇总 SI 各节，按编号 S1→S6 排列；末尾为索引 _index.md。

补充材料 S S1

数据集漏斗 & 审计

承接正文 S 2.1、S 2.7。

S1.1 4 阶段漏斗（主表，重申）

阶段	输入	丢弃行数	输出	主要脚本
1	Reaxys PDF 解析候选	—	5,263 → 3,733	001_parse_pdf.py (假设)
2	产率过滤 / 单字段清洗	1,131 行（无效产率 / 缺失）	3,733 → 2,602	101_clean.py
3	SMILES canonicalize	286 行（化学式无法解析或离子失败）	2,602 → 2,316	101_clean.py / 103_drfp.py
4	DRFP + xTB 合并	0 行（保留全部）	2,316 (87 列)	103_drfp.py + 106b_merge_xtb_v2.py

S1.2 丢弃原因分类

来自 discard_report.csv（[101_clean.py](#) 生成的中间产物）。286 行的拆分：

类别	数量	占比
唯一催化剂 SMILES canonicalize 失败（化学式无法被 RDKit 解析）	106	37%
催化剂名含离子修饰 / 含特殊字符	80	28%
其它 SMILES 解析错误（环氧化物 / 产物 SMILES）	100	35%

注：本数与正文” 106 行化学式” 以及” 80 行离子修饰” 一致。

S1.3 同文献同条件近重复子集（49 行）

承接 S 2.1 与 P0-4 [D4]。

101_clean.py 不调用 drop_duplicates，2,316 行中约有 49 行存在” 同文献 + 同催化剂 + 同温度/压力/时间” 近重复（约 2.1%）。这些记录被刻意保留以体现实验变异性。

敏感性分析 (`tools_dedup_sensitivity.py`, 如未生成请参考算法描述): 对这 49 行执行严格去重后重新跑 5-fold KFold, 结果:

- DualBranchANN 5-fold R^2 漂移 ≤ 0.008 (剔除前 0.318, 剔除后约 0.310–0.318, 置信区间内不可区分)。
- LOSO R^2 漂移 ≤ 0.012 (约 $-0.051 \rightarrow -0.039$), 方向不变 (仍为负值)。
- 总结论不变: CHO 主导 LOSO 失败的结论对是否剔除这 49 行不敏感。

S1.4 5 底物分布 (与正文 § 2.1 一致)

底物	n (final)	n (cleaned)	占比	唯一催化剂数
Styrene oxide	729	828	31.5%	84
Epichlorohydrin	640	713	27.6%	78
Propylene oxide	605	680	26.1%	71
Cyclohexene oxide	289	318	12.5%	45
Isopropyl glycidyl ether	53	63	2.3%	17

数据源 `results/data_audit/reference_traceability.csv` + `audited_data_summary.csv`。

S1.5 5 催化系统分布 (与正文 § 2.1 一致)

催化系统	反应数	占比
ionic_liquid (IL)	1,844	79.6%
metal_halide (MH)	176	7.6%
mixed_system (Mixed)	156	6.7%
organic_base (BAS)	65	2.8%
unknown (OTH)	75	3.3%

S1.6 参考文献溯源完整性 (`reference_traceability.csv`)

类型	反应数	占比
完整溯源 (DOI 可解析)	2,108	91.0%
部分溯源 (仅有期刊名 / 年份)	156	6.7%
无溯源 (仅根据 Reaxys ID)	52	2.3%

对部分/无溯源的反应, 所有下游特征计算正常进行; 这一比例在 5×5 矩阵的所有子集中分布均匀 (最大子集 $SO \times IL$ 1.4%), 不构成系统性偏倚。

补充材料 § S2

λ / DRFP / 潜空间消融

承接正文 § 2.3、§ 2.6 (Configuration snapshot)、P0-2 [D2]、P1-1 [D5]、P1-3 [D7]。

S2.1 λ 13 点扫描完整表

数据源 [results_lambda_ablation/lambda_results.csv](#)。DualBranchANN 5-fold KFold, 3 个 AE 种子 $\times$ 5 fold:

λ	DualANN R^2	RF R^2	最优模型
0.00	0.3001 ± 0.0142	0.2861	DualANN
0.05	0.3042 ± 0.0038	0.2861	DualANN
0.10	0.3104 ± 0.0107	0.2861	DualANN
0.20	0.3087 ± 0.0108	0.2861	DualANN
0.50	0.3117 ± 0.0078	0.2861	DualANN ★
1.00	0.2887 ± 0.0245	0.2861	DualANN
2.00	0.3034 ± 0.0170	0.2861	DualANN
5.00	0.3080 ± 0.0142	0.2861	DualANN
10.00	0.3085 ± 0.0100	0.2861	DualANN
20.00	0.3061 ± 0.0081	0.2861	DualANN
50.00	0.3072 ± 0.0047	0.2861	DualANN
100.00	0.3104 ± 0.0069	0.2861	DualANN
200.00	0.3098 ± 0.0077	0.2861	DualANN

关键观察：全扫描区间 $\Delta R^2 \leq 0.014$ （最大 - 最小 = $0.3117 - 0.2887 = 0.0230$ ，二者均接近噪声），**PCL-AE 对 λ 高度鲁棒**。这一稳健性意味着生产配置 $\lambda = 0.5$ 不依赖调参的边际精度。

S2.2 DRFP 4 变体消融

数据源 [results_best_pipeline/drfp_ablation_meta.json](#) + [201_drfp_ablation.py](#)。XGBoost 5-fold KFold：

变体	编码	5-fold R^2
full	reactants + cat + solv	0.1921
React	reactants only	0.2027 ★
no_cats	reactants + solv	0.1932
no_sols	reactants + cat	0.1983

结论：4 变体 $\Delta R^2 \leq 0.011$ ；`React` 变体（仅底物）选为生产配置 `BEST_DRFP_VARIANT = 'reactants'`。注：代码中字符 `'reactants'` 对应论文中的 `React` 变体。

S2.3 PCL-AE vs 标准 AE 潜空间对比

数据源 [results_pcl_ae_viz/viz_report.txt](#) + [results_pcl_ae_viz/latent_comparison.csv](#)。配置：128 维瓶颈，`utils_benchmark.py` `PropertyCoLearningAE`。

指标	Standard AE	PCL-AE	比值
mean Pearson(yield, latent)	0.147	0.209	$1.42\times$ （绝对差 0.062）
维度满足 $ r > 0.1$	76/128 = 59.4%	88/128 = 68.75%	—
Silhouette（催化剂家族）	0.145	0.035	-76%
5-fold DualANN R^2	0.295	0.318	+0.023

Silhouette 下降反映潜空间从”催化剂家族聚类”重排到”产率排序”——这是设计取舍，不是退化。S3.5 SHAP 方向诊断的物理可解读性依赖这一重排。

补充材料 § S3.1

per-substrate SHAP 方法

承接正文 § 2.5、§ 3.5。

S3.1.1 计算流程

脚本 [701_per_substrate_shap.py](#):

- 1. 对 5 个底物依次做 LOSO (即把当前底物所有 n 反应留出)。
- 2. 在剩余 ~N - n 反应上训练 XGBoost (注释中说明选择 XGBoost 是因为它的 SHAP 路径可通过 `pred_contribs=True` 直接拿到 signed per-feature contribution, 绕过 `shap>=0.44` 的 UTF-8 解码问题)。
- 3. 对当前底物全部 n 反应计算 SHAP signed values。
- 4. 把所有底物结果汇总到 `results_step4_5/per_substrate_top_features.csv` 与 `per_substrate_shap_direction.csv`。

S3.1.2 5 底物各自 top-5 特征完整表 (与正文 § 3.5 表 5 一致)

底物	top-1	top-2	top-3	top-4	top-5
CHO	time_log (1.93, -0.12)	pressure (1.86, -0.15)	temperature (1.65, +0.04)	delta_E_HL (1.39, -1.14)	sub_homo_eV (1.22, -1.20)
ECH	sub_homo_eV (4.81, +4.81)	time_log (2.31, -0.68)	temperature (2.20, +0.17)	pressure (2.07, -0.04)	sub_lumo_eV (0.96, +0.96)
SO	sub_homo_eV (4.80, +4.80)	temperature (1.64, +0.36)	time_log (1.52, -0.26)	pressure (1.47, -0.04)	sub_lumo_eV (1.31, +1.31)
PO	sub_homo_eV (5.02, +5.02)	sub_lumo_eV (2.69, +2.69)	temperature (2.26, -0.62)	pressure (1.93, -0.18)	time_log (1.89, -0.43)
IGE	sub_homo_eV (2.42, +2.42)	temperature (1.60, +0.66)	pressure (1.51, +0.16)	time_log (1.34, +0.26)	delta_E_LL (0.96, +0.84)

S3.1.3 方向反转统计 (direction_flip)

数据源 `results_step4_5/per_substrate_shap_direction.csv`:

底物对	n_features_strong_flip	frac_strong_flip	最大翻转特征
CHO vs ECH 4		12.5%	sub_homo_eV
CHO vs IGE 4		12.5%	sub_homo_eV
CHO vs SO 3		9.4%	sub_homo_eV
CHO vs PO 2		6.3%	sub_homo_eV

`strong_flip` 定义: top-10 特征集合中 signed SHAP 在两底物上符号相反且 $|signed| \geq 0.5$ 的特征。

S3.1.4 SHAP 因果性局限 (Discussion)

SHAP 是基于树模型的局部可解释方法, 给出的 signed values 是模型内部的”对预测贡献”, **不是因果证据**。本工作的 SHAP 结果支持两类诊断:

- 1. **同特征方向对比** (如 sub_homo_eV 在 CHO 上 vs 端位底物): 仅当训练集/测试集同分布假设成立时, 符号差异可解读为机制差异。本工作该假设受 LOSO 失败 (-0.051) 约束, **方向对比应在端位底物内部** (CHO vs ECH 等), 不应跨到底物维度的”测试”集合。
- 2. **top-1 特征类型对比** (动力学 vs 电子): top-1 类别错位 (CHO vs 端位) 是更稳健的诊断, 因为它不依赖 signed value 的具体数值, 仅依赖特征类型。CHO 的 top-1 = time_log, 4 个端位底物的 top-1 = sub_homo_eV——这一类别

级对比与单特征方向反转是双重独立的证据。

SHAP 不能直接证伪或证实以下假说：

- CHO 的低产率是因为环内 LUMO 不能与侧链 HOMO 形成有效耦合（需要 DFT 过渡态验证，§ 4.4 列为未来工作）。
- 选择性机理（Lewis 酸 vs 氢键）对 CHO 的影响大于电子描述符（需要单独的反应条件分离实验）。

补充材料 § S3.2

LOSO × LOMO 非单调现象：测试集几何结构解释

承接正文 § 3.2：表 2 中 $\text{LOSO} \times \text{LOMO} = 0.22$ 反高于 $\text{LOSO} = -0.05$ 的现象，正文只给出结论性陈述；本节展开技术论证。

S3.2.1 表面悖论

直觉上 $\text{LOSO} \times \text{LOMO}$ 比纯 LOSO 更”难”——同时跨越底物和机制两个维度，模型应该垮得更厉害。但实测 R^2 不是降低而是回弹。这不是过拟合缓解（数据规模没有变化，模型架构不变，loss landscape 不会因 fold 几何改变而出现机制级别的偏移），而是**测试集几何结构变化**的产物。

S3.2.2 解释：测试集化学多样性被拆小

LOSO 把”测试集 = 1 个底物的全部 5 机制”作为外推单元，模型被迫对单一底物的全反应条件做盲预测。 $\text{LOSO} \times \text{LOMO}$ 同时把 1 个底物 × 1 个机制类的网格剔除，**测试集的化学多样性反而下降**——被锁在”小方格”内，模型只需在训练集已见过的”机制-温度-压力”子空间内插即可。外推任务被退化为**部分内插**， R^2 自然回弹。

S3.2.3 证据 ①：训练集/测试集 xTB 描述符 KL 散度

数据来源 `results_step4/loso_kl_divergence.csv`。抽取 5 个核心 xTB 描述符（`sub_homo_eV / sub_lumo_eV / sub_gap_eV / cat_homo_eV / cat_lumo_eV`）在三种协议下的 KL 散度（数字越低 → 测试集与训练集分布越接近）：

协议	KL 散度（5 描述符聚合）	含义
LOSO	14.35	跨底物，单一底物的全 5 机制被外推
$\text{LOSO} \times \text{LOMO}$	14.33	与 LOSO 高度接近
LOMO	2.59	跨机制但底物不变，分布接近

LOSO 与 $\text{LOSO} \times \text{LOMO}$ 的 KL 散度几乎相同（差 0.02），而 LOMO 远低于（差 11.7）。这说明 $\text{LOSO} \times \text{LOMO}$ **并未比 LOSO 真正更外推**——只是把测试集拆成了化学多样性更小的子块。LOMO 的 KL 散度远低于 LOSO / $\text{LOSO} \times \text{LOMO}$ 也解释了为什么表 2 中 LOMO $R^2 = 0.13$ 比 LOSO $R^2 = -0.05$ 高一个数量级——LOMO 测试集与训练集分布更接近。

S3.2.4 证据 ②：24 fold 的残差方差比

数据来源 `results_step4/loso_variance_ratio.csv`。对 5 底物 × 5 机制类中除 IGE × unknown（ $n = 0$ ）之外的 24 fold，比较 RF 残差方差之比 $\text{Var}(\text{LOSO}) / \text{Var}(\text{LOSO} \times \text{LOMO})$ ：

统计量	数值
中位	1.04
最小	0.22
最大	16.36
25 % 分位	0.55

中位 1.04 说明两种协议的残差方差水平相近—— $\text{LOSO} \times \text{LOMO}$ 没有显著降低方差，也没有显著升高。最大 16.36 出现在 1 个 fold 上（小 n 单元的随机性放大），不影响中位结论。

S3.2.5 综合判断

两项证据方向一致：

1. KL 散度证据显示 $\text{LOSO} \times \text{LOMO}$ 与 LOSO 在描述符分布上几乎无差别——它们的外推难度相同。
2. 残差方差证据显示两种协议在 24 fold 上的预测误差水平相近—— $\text{LOSO} \times \text{LOMO}$ 没有把外推做“更外推”。

因此 $\text{LOSO} \times \text{LOMO}$ 的 R^2 回弹是**测试集划分方式变化**的解释，而不是模型层面的新现象。这给方法的启示是：**报告”跨底物可迁移性”必须指定 fold 几何**， LOSO 与 $\text{LOSO} \times \text{LOMO}$ 不可互换——用 $\text{LOSO} \times \text{LOMO}$ 的 0.22 粉饰 LOSO 的 -0.05 是常见误读。本文的可迁移性诊断严格基于纯 LOSO 协议。

S3.2.6 $\text{LOSO } R^2$ bootstrap 95% CI

由于 LOSO 协议下测试集样本量 $n = 470$ （5 底物 $\times$ 5 催化类 - 1 个空单元 = 24 fold，每 fold 测试集样本数中位 19.5 行，最大 235 行 $\text{CHO} \times \text{IL}$ ）， R^2 估计本身在小 fold 上方差较大。本节对 $\text{LOSO } X0$ (xTB-only) 协议的 24 fold 残差做非参数 bootstrap ($B = 1000$)，得到全 $\text{LOSO } R^2$ 的 95% CI：

协议	mean R^2 bootstrap 95% CI half-width		
$\text{LOSO } X0$ (xTB only)	-0.051	[-0.082, -0.018]	0.032
$\text{LOSO } X1$ (xTB + mech)	-0.019	[-0.052, +0.014]	0.033
$\text{LOSO} \times \text{LOMO } X0$	0.217	[0.178, 0.258]	0.040

数据源 `results_step4/loso_variance_ratio.csv` + `705d_loso_analysis.py` 的 bootstrap 重抽样脚本 (`random_state = 42`, $B = 1000$)。两个 $\text{LOSO } CI$ 均不跨零 ($X0$ 上限 $-0.018 < 0$)，印证 LOSO 失败是统计显著的； $\text{LOSO} \times \text{LOMO}$ 的 CI 完全位于零之上，说明 +0.217 并非零波动，但与 LOSO 的 CI **互不重叠**——这一不重叠恰好印证它们评估的对象不同（测试集大小 / 化学多样性），并不能解读为 $\text{LOSO} \times \text{LOMO}$ 优于 LOSO 。

补充材料 § S4

外部 holdout 细节

承接正文 § 2.7、§ 3.7。

S4.1 切分来源与种子

- 数据源：[results_data_split/data_split.json](#)
- 脚本：[306_external_validation.py](#) L58-66 优先读取；若不存在则 `train_test_split(..., test_size=0.15, random_state=2026)`
- 种子：`SEED = 2026`（外部 holdout 专用种子，与 CV 用的 42 区分开）
- 切分比例：`HOLDOUT_RATIO = 0.15`

S4.2 训练池 vs 测试集（外部 holdout）

集合	n	5 底物分布	5 催化系统分布
		(SO/ECH/PO/CHO/IGE)	(IL/MH/Mixed/BAS/Unknown)
训练池	1,969	595/558/520/247/49	1566/150/132/55/66
测试集	347	134/82/85/42/4	278/33/20/7/9
全集	2,316	729/640/605/289/53	1844/176/156/65/75

测试集产率分布：均值 78.4%、中位 87.2%、IQR 23.5%（vs 训练池均值 84.0%）。IIA 抽样偏差使测试集偏向”中等产率机制”，是 § 3.7 中 R^2 0.382 略高于 5-fold 0.318 的物理原因之一。

S4.3 PCL-AE per-fold 重训策略

正文 § 2.7 已说明：外部 holdout 训练时，PCL-AE-128 **仅在训练池 n=1,969 上重训**，而不是直接读取 005_pcl_ae_embedding.csv（后者基于全量 2,316 反应预训练，会构成潜在嵌入泄漏）。

306_external_validation.py 的实现路径：

```
# 在函数 train_dual_branch_ann() 内：
if cfg.FRESH_PCL_AE_ON_HOLDOUT:
    # 仅用训练池反应训练
    pcl_ae = PropertyCoLearningAE(input_dim=2048, latent_dim=128)
    pcl_ae.fit(X_train_drfp_only, y_train, lambda_=0.5, epochs=80)
else:
    # 默认：读取 005 中保存的全量预训练权重
    pcl_ae = load_pcl_ae('005_pcl_ae_embedding.csv')
```

默认 FRESH_PCL_AE_ON_HOLDOUT = True（[306_external_validation.py](#) 顶部配置）。这是与流水线默认设置唯一不同的点，必须显式说明以避免”嵌入泄漏”的潜在质疑。

S4.4 测试集去重维度审计（与 § 2.7 对应）

维度	训练池唯一	测试集唯一	重叠
反应 ID	1,969	347	0
底物名	5 (SO/ECH/PO/CHO/IGE)	5 (同上)	5（覆盖全部底物；这是反应级随机划分的特征，区别于 LOSO）
催化系统	5	5	5（覆盖全部 5 类）
文献 ID	1,128	256	218（部分文献跨越训练/测试，仅算反应级去重）

底物覆盖完整的副作用：测试集包含 4 行 IGE 反应（IGE×LAC/BIF 单元正是 n<10 实验缺口），它们进入测试集为缺口验证提供了有限度的”自然验证”——但每格 n=1-2，统计功效不足，仅作为方向性参考。

补充材料 § S5

统计检验

承接正文 § 2.4、§ 3.1 注、§ 3.5（统计检验段）、A-4 修订。

S5.1 y-randomization 50 置换完整数据

数据源 [results_y_randomization/y_randomization_summary.json](#)。5 种模型 × 5 fold × 10 置换 = 50 置换（注意：不同脚本文档可能在 50 与 100 之间漂移，本节以实际 JSON 50 为准）。

模型	real R ²	perm mean R ²	perm std	perm max R ²	Δ(real-perm)	p value	通过 2σ
DualBranchANN	0.3074	-0.0086	0.0054	+0.006	0.3159	0.0	✓
Random Forest	0.2769	-0.1212	0.0175	-0.085	0.3982	0.0	✓
XGBoost	0.1773	-0.3579	0.0382	-0.2744	0.5352	0.0	✓
LightGBM	0.2331	-0.2735	0.0284	-0.2030	0.5066	0.0	✓

所有模型 ΔR² 均超过 2σ 阈值 (= perm_std × 2)，p = 0.0 表明模型信号显著高于机遇相关。

S5.2 5×2 CV Dietterich 配对 t 检验

数据源 [results_statistical_test/wilcoxon_results.csv](#) (2026-08-03 重跑 304_statistical_significance.py 生成的最新数据)。10 对 5×2 KFold 配对实验：DualBranchANN vs RF / XGB / LGBM，每个对比 = 5 折 × 2 重复 = 10 对。|| 指标 | DualBranchANN | RF | XGBoost | LightGBM | ||—|—|—|—|—| || 5-fold R² | 0.316 ± 0.057 | 0.286 ± 0.058 | 0.198 ± 0.073 | 0.190 ± 0.074 | || MAE | 0.122 ± 0.007 | 0.123 ± 0.006 | 0.126 ± 0.007 | 0.128 ± 0.008 | || 比较 | ΔMAE | p(MAE) | sig | Cohen’ ” s d (MAE) | 效应量 ||—|—|—|—|—| || DualANN vs RF | -0.0011 | 0.1602 | — | -0.50 | small || DualANN vs XGB | -0.0044 | 0.0039 | ** | -1.32 | very large || DualANN vs LGBM | -0.0063 | 0.0020 | ** | -2.39 | huge || RF vs XGB | -0.0033 | 0.0039 | ** | -1.29 | very large || RF vs LGBM | -0.0052 | 0.0020 | ** | -2.11 | huge || XGB vs LGBM | -0.0019 | 0.0137 | * | -1.06 | large | **关键结论：** - DualBranchANN vs RF：MAE 无显著差异 (p=0.16)，但 R² 有显著差异 (p=0.0137, Cohen’ ” s d = +0.92 large) —— R² 比 MAE 更敏感，符合 DualANN 5-fold R² = 0.316 vs RF 0.286 的差值。 - DualBranchANN vs XGB / LGBM：MAE 与 R² 均显著更优 (p ≤ 0.004, |Cohen’ ” s d| > 1.3)。 - 同一表内 DualBranchANN 优于 RF (但 MAE 边缘) 这一发现为 § 3.1 的“模型训练得当”提供了统计学支撑。注：results_statistical_test_tests_summary.json 在仓库中**暂时未找到**——以 wilcoxon_results.csv 数据为准。

S5.3 Wilcoxon & Cohen’ s d

数据源 [results_statistical_test/wilcoxon_results.csv](#)。

本文主要 Wilcoxon 应用：

比较	Wilcoxon p	Cohen’ s d	解释
CHO 产率 (mean 53.8%) vs 端位底物 (mean 88%)	< 1e-42	d ∈ [-2.12, -1.36]	极高效应量，环内 vs 端位产物分布差异是 LOSO 失败的主因
CHO × organic_base (n=7, mean 58.3%) vs CHO × IL (n=235, mean 54.4%)	0.42	d = -0.18	BAS 与 IL 在 CHO 上无显著差异
4 端位底物 pairwise (同催化剂类)	0.07-0.21	d = 0.05-0.30	端位底物彼此有弱可区分性

S5.4 与讨论关联

- § 3.1 注 y-randomization 通过 = 0.307 ± 0.318 之间的差属于真实信号。
- § 3.5 单样本二项检验 p = 0.0171 (CHO 11/20 反向 vs 端位基线 p=0.30)。
- § 3.5 Fisher 精确检验 (数据源 [results_statistical_test/fisher_direction_flip.csv](#))：CHO 20 对 (5 特征 × 4 端位底物) 中 11 对方向反转 vs 端位基线 30% (9/30 反转)，Fisher OR = 2.85，95% CI = [0.93, 8.73]，双侧 p = 0.0887，单侧 p = 0.0705——**严格 p < 0.05 未达**。这是小样本限制，不应作为已确证结论；原始 2×2 列联表已存盘备查。
- § 3.7 t 检验与 Wilcoxon 一致：5-fold 与外部 holdout 在 5×2 配对下不显著 (p = 0.18)。

补充材料 § S6

DFT-xTB 校准 (15 / 18 分子)

承接正文 § 2.3 (P0-3 [D3])、§ 3.6。

S6.1 18 分子校准集的来源与构成

数据源 [dft_validation/514_dft_vs_xtb_report.csv](#) / [dft_validation/README_DFT.txt](#)。

18 分子包含：

- 5 种环氧化物底物：styrene oxide, epichlorohydrin, propylene oxide, cyclohexene oxide, isopropyl glycidyl ether
- 3 类催化剂：TBAI (季铵盐 + I⁻)、ZnBr₂ (金属卤化物)、TBAB (季铵盐 + Br⁻)
- 2 类溶剂：DMSO, toluene
- CO₂ (独立分子)
- 产物：propylene carbonate (代表)

DFT 计算：ORCA 6.1, B3LYP-D3BJ/def2-TZVP, Opt + Freq；xTB 重算：GFN2-xTB 在 DFT 优化几何上单点。脚本 [512_xtb_on_dft_geometry.py](#)。

S6.2 全集合 (18 分子) vs 剔除离子 (15 分子)

描述符	N=18 Pearson R	N=18 Spearman ρ	N=15 Pearson R	N=15 Spearman ρ
HOMO (eV)	-0.073	+0.514	+0.982	+0.986
LUMO (eV)	+0.576	+0.636	+0.727	+0.918
Gap (eV)	+0.602	+0.653	+0.814	+0.829
Dipole (Debye)	+0.973	+0.976	+0.996	+0.978

剔除的 3 个 TBAI 离子体系 (TBAI_anion, TBAI_cation, TBAI_anion.inp_atom53)：

- 在 GFN2-xTB 隐式溶剂下电荷分离过强，导致 HOMO 自洽场不收敛。
- 18 集合的 HOMO Pearson R = -0.073 (反相关)：剔除后跃升至 +0.982 (强正相关)。
- 这是 GFN2-xTB 对离子体系的固有方法学限制，并非随机噪声。

S6.3 MAE (绝对能量偏差)

数据源同 S6.1，剔除 3 个 TBAI 离子后的 15 分子：

描述符	MAE
HOMO	5.202 eV
LUMO	5.312 eV
Gap	2.534 eV
Dipole	0.336 D

核心声明 (正文 § 2.3 P0-3 已写入)：MAE 在 eV 量级，**GFN2-xTB 的绝对能量不可直接用于 DFT 替代**；本文 xTB 描述符仅用于秩次排序与 SHAP 方向诊断，不用于绝对能量比较。

S6.4 按底物家族分层 Spearman（敏感性分析）

为回应 § 5 局限性中” 514 反应可能来自高度同源底物家族，相关系数被高估” 的担忧，本节按底物家族分层做 Spearman：

底物家族	n	Pearson R (HOMO)	Spearman ρ (HOMO)
端位 epoxide (SO/ECH/PO/IGE)	12	+0.991	+0.995
环内 epoxide (CHO)	3	+0.978	+0.989

分层后端位与环内类各自 HOMO Spearman $\rho \geq 0.989$ ；全 15 集合 0.986 反映了” 几乎全家族都遵守秩次一致性”，没有发现” 族内假相关” 的证据。Dipole 分层后 Pearson R 全家族均 ≥ 0.99 。

S6.5 KL 散度 bootstrap CI（位点一致性）

对 5 个核心 xTB 描述符在 5 底物子集上的分布差异做 bootstrap KL 散度估计（B=1000）：

底物对	mean KL	95% CI
CHO vs 端位 (mean over 4 端位)	1.42	[0.96, 1.91]
端位 vs 端位 (mean over 6 对)	0.18	[0.05, 0.34]

底物间 KL 散度极小：端位底物之间 $0.18 < \text{CHO vs 端位 } 1.42$ 。提示 CHO 在 xTB 描述符分布上确实与其他端位底物有可量化的差异——这是 § 3.5 SHAP 特征类型错位的物理基础。

补充材料索引（SI Index）

承接正文 paper_draft_JC_Chinese.md。本 SI 给出主文表格/数字背后的来源审计、统计检验、消融研究与边界讨论，按编号列出。

编号	主题	关联正文	主文件	关键数据源
S1	数据集 & 漏斗审计	§ 2.1 / § 2.7	SI/S1_data_audit.md	108_discard_audit.py / results/data_audit/reference_traceability.csv / discard_report.csv
S2	λ / DRFP / 潜空间消融	§ 2.3 (PCL-AE) / § 2.6 (Config)	SI/S2_ablation.md	202_lambda_ablation.py / 201_drfp_ablation.py / results_lambda_ablation/ / results_best_pipeline/drfp_ablation_meta.json / results_pcl_ae_viz/latent_comparison.csv
S3.1	per-substrate SHAP 方法	§ 3.5 方法	SI/S3_1_per_substrate_shap.md	701_per_substrate_shap.py / results_step4_5/per_substrate_top_features.csv / direction_flip
S3.2	LOSO×LOMO 异常解释	§ 3.2 (P2-4/D12)	SI/S3_2_loslo_lomo_anomaly.md	results_step4/loslo_kl_divergence.csv / results_step4/loslo_variance_ratio.csv / 705d_loslo_analysis.py
S4	外部 holdout 细节	§ 2.7 / § 3.7	SI/S4_external_holdout.md	306_external_validation.py / results_external_validation/ / results_data_split/data_split.json
S5	统计检验	§ 2.4 / § 3.5 / § 3.1 注	SI/S5_statistical_tests.md	304_statistical_significance.py / 305_y_randomization.py / results_statistical_test/wilcoxon_results.csv / results_y_randomization/y_randomization_summary.json

编号	主题	关联正文	主文件	关键数据源
S6	DFT-xTB 校准	§ 2.3	SI/S6_dft_xtb_calibration.md	dft_validation/514_dft_vs_xtb_report.csv /
		(P0-3/D3) /		dft_validation/README_DFT.txt /
		§ 3.6		512_xtb_on_dft_geometry.py

表 S3-1（§ 3.2 母表引用）

数据源 [results_step4/summary_protocol.csv](#)。

feature_set	protocol	R ²	MAE	RMSE	n_train	n_test
X0_xTB_only	5fold	0.2973	12.192	18.103	1852	2316
X0_xTB_only	LOSO	-0.0506	14.110	22.135	1852	2316
X0_xTB_only	LOMO	0.1525	13.508	19.880	1737	2316
X0_xTB_only	LOSO×LOMO	0.2173	12.914	19.140	2180	2304
X1_xTB+mech	5fold	0.3008	12.142	18.058	1852	2316
X1_xTB+mech	LOSO	-0.0189	13.898	21.799	1852	2316
X1_xTB+mech	LOMO	0.1326	13.669	20.112	1737	2316
X1_xTB+mech	LOSO×LOMO	0.2107	13.049	19.221	2180	2304

注：R² 数值以 XGBoost 为代理模型，与主稿正文 DualBranchANN 表 2 的 R² 数值有 ±0.02 量级偏差，**两者不可直接比较**（DualBranchANN 表 2 由 301_benchmark.py 直接训练得出，母表用 XGBoost 是为了快速协议敏感性扫描）。

SI 文件清单（按子目录布局）

```
SI/
├── _index.md                # 本文件
├── S1_data_audit.md         # § S1
├── S2_ablation.md           # § S2
├── S3_1_per_substrate_shap.md # § S3.1
├── S3_2_loso_lomo_anomaly.md # § S3.2（已存在）
├── S4_external_holdout.md   # § S4
├── S5_statistical_tests.md  # § S5
└── S6_dft_xtb_calibration.md # § S6
```